



UNIVERSITATEA DIN  
BUCUREȘTI

FACULTATEA DE  
MATEMATICĂ ȘI  
INFORMATICĂ



SPECIALIZAREA INFORMATICĂ

Lucrare de licență

APLICAȚIE WEB PENTRU VIDEOCLIP-URI CU  
FUNCȚII DE ÎNȚELEGEREA VORBIRII ȘI  
REGĂSIRE PE BAZĂ DE TEXT

Absolvent

Trifan Robert-Gabriel

Coordonator științific

Prof. Dr. Ionescu Radu

București, iunie 2024

## **Rezumat**

Popularitatea videoclipurilor a avut o creștere constantă în ultimii ani, reprezentând 82.5% din traficul web în 2023. Statistici recente arată că oamenii petrec în media 17 ore pe săptămâna vizionând videoclipuri online, acestea fiind cu 52% mai predispuse să fie distribuite pe rețelele de socializare decât alte tipuri de conținut. [3]

În acest context, lucrarea de față își propune să contribuie la creșterea accesibilității și personalizării conținutului video, prin dezvoltarea unei aplicații web care permite adăugarea de subtitrări, căutarea videoclipurilor pe bază de text și clasificarea acestora în funcție de conținutul lor. Aplicația oferă utilizatorilor posibilitatea de a vizualiza subtitrările în timp real și de a căuta cuvinte cheie în metadatele videoclipurilor precum titlu, descriere, topic și subtitrare.

## **Abstract**

The popularity of videos has been steadily increasing in recent years, representing 82.5% of web traffic in 2023. Recent statistics show that people spend an average of 17 hours a week watching online videos, which are 52% more likely to be shared on social networks than other types of content. [3]

In this context, this work aims to contribute to increasing the accessibility and personalization of video content, by developing a web application that allows the addition of subtitles, searching for videos based on text and classifying them according to their content. The application offers users the possibility to view subtitles in real time and to search for keywords in the metadata of videos such as title, description, topic and subtitle.

# Cuprins

<b>1</b>	<b>Introducere</b>	<b>4</b>
1.1	Motivație . . . . .	4
1.2	Domenii abordate . . . . .	4
1.3	Structura lucrării . . . . .	5
<b>2</b>	<b>Inteligență artificială</b>	<b>6</b>
2.1	Recunoașterea vorbirii . . . . .	6
2.1.1	Arhitectura modelului . . . . .	6
2.1.2	Setul de date . . . . .	9
2.1.3	Antrenarea modelului . . . . .	11
2.1.4	Postprocesare . . . . .	11
2.2	Clasificarea videoclipurilor . . . . .	11
2.2.1	Arhitectura modelului . . . . .	11
2.2.2	Setul de date . . . . .	11
2.2.3	Antrenarea modelului . . . . .	11
2.2.4	Postprocesare . . . . .	11
2.3	Concluzii . . . . .	11
<b>3</b>	<b>Inginerie software</b>	<b>12</b>
3.1	Frontend . . . . .	12
3.2	Backend . . . . .	12
3.2.1	Server . . . . .	12
3.2.2	Recunoașterea vorbirii . . . . .	12
3.2.3	Clasificarea videoclipurilor . . . . .	12
3.3	Baze de date . . . . .	12
3.3.1	MongoDB . . . . .	12
3.3.2	Elasticsearch . . . . .	12
	<b>Bibliografie</b>	<b>13</b>

# Capitolul 1

## Introducere

### 1.1 Motivație

Motivul pentru care am ales această temă îl reprezintă nevoia de subtitrări pentru videoclipuri, în special pentru filme, dar și pentru tutoriale sau alte tipuri de conținut video, a căror înțelegere este îngreunată de calitatea slabă a sunetului sau de faptul că sunt într-o limbă străină. Astfel, în această lucrare, am ales să abordez problema subtitrărilor prin intermediul unui model de recunoaștere a vorbirii, care extrage audio dintr-un videoclip și generează textul corespunzător.

De asemenea, am ales să abordez și problema căutării videoclipurilor, care constă în căutarea cuvintelor cheie în metadate precum titlu, descriere, topicuri sau chiar în conținutul videoclipului, folosind o bază de date special concepută pentru acest scop, Elasticsearch. [4]

### 1.2 Domenii abordate

Această lucrare abordează 5 domenii principale:

- **Procesarea semnalelor audio** - pentru extragerea audio din videoclipuri și recunoașterea vorbirii
- **Procesarea limbajului natural** - pentru clasificarea videoclipurilor în funcție de conținutul lor
- **Frontend** (*React.js*) pentru interfața cu utilizatorul și pentru a oferi acces la funcționalitățile sistemului
- **Backend** - pentru gestionarea cererilor prin intermediul unui API, cu ajutorul a 3 servicii principale:
  - **Server** (*Node.js*, *Express.js*) pentru gestionarea cererilor și a răspunsurilor

- **Recunoașterea vorbirii** (*Flask*) pentru gestionarea cererilor de recunoaștere a vorbirii
- **Clasificarea videoclipurilor** (*Flask*) pentru clasificarea videoclipurilor în funcție de conținutul lor
- **Baze de date**
  - **MongoDB** pentru stocarea metadatelor videoclipurilor
  - **Elasticsearch** pentru căutarea videoclipurilor în funcție de cuvintele cheie

## 1.3 Structura lucrării

Voi împărți această lucrare în 2 capitole principale, fiecare cu subcapitolele sale.

- **Inteligență artificială** - în care voi aborda *recunoașterea vorbirii* și *clasificarea videoclipurilor* și voi prezenta setul de date folosit, arhitectura modelului, antrenarea și evaluarea acestuia, precum și procesările ulterioare
- **Inginerie software** - în care voi aborda partea de frontend, backend și baze de date, precum și detaliile tehnice ale implementării

# Capitolul 2

## Inteligență artificială

### 2.1 Recunoașterea vorbirii

Pentru a putea recunoaște vorbirea dintr-un videoclip, am ales să folosesc arhitectura *wav2vec 2.0* [2] dezvoltată de Facebook AI Research. Am folosit atât modelul *facebook/wav2vec2-base-960h* antrenat pe setul de date *LibriSpeech* [6], cât și modelul preantrenat *facebook/wav2vec2-base* pe care am continuat să-l antrenez pe seturile de date *Mini LibriSpeech* (subset din *LibriSpeech*) și *Common Voice Delta Segment 16.1* (subset din *Common Voice*) [1].

#### 2.1.1 Arhitectura modelului

Modelul *wav2vec 2.0* este un model de învățare profundă alcătuit din 4 componente principale: Latent Feature Encoder (Convolutional Network), Context Network (Transformer Encoder), Quantization Module (Gumbel Softmax) și Contrastive Loss. 2.1




Figura 2.1: Arhitectura modelului *wav2vec 2.0* <sup>1</sup>

## Latent Feature Encoder

Componenta Latent Feature Encoder este o rețea convoluțională care primește ca intrare un semnal audio și aplică o serie de operații de convoluție, normalizare și activări GELU pentru a extrage caracteristici latente din semnalul audio. 2.2

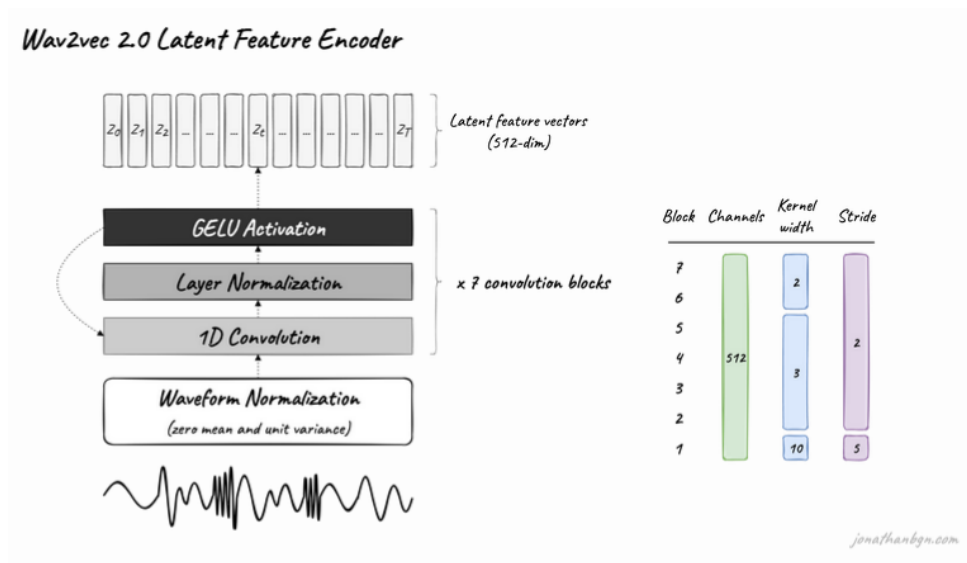


Figura 2.2: Arhitectura componentei Latent Feature Encoder <sup>1</sup>

## Context Network

Componenta Context Network este un encoder de tip Transformer care primește ca intrare caracteristicile latente extrase de componenta Latent Feature Encoder și le procesează pentru a obține o reprezentare contextuală a semnalului audio. Aducând aminte de arhitectura modelului anterior *wav2vec* [7], care folosea tot o rețea convoluțională la acest pas, ar părea că se aseamănă cu componenta anterioară. Diferența constă în faptul că Latent Feature Encoder urmărește să reducă dimensiunea semnalului audio, în timp ce Context Network urmărește să înțeleagă un context mai larg al semnalului audio. 2.3

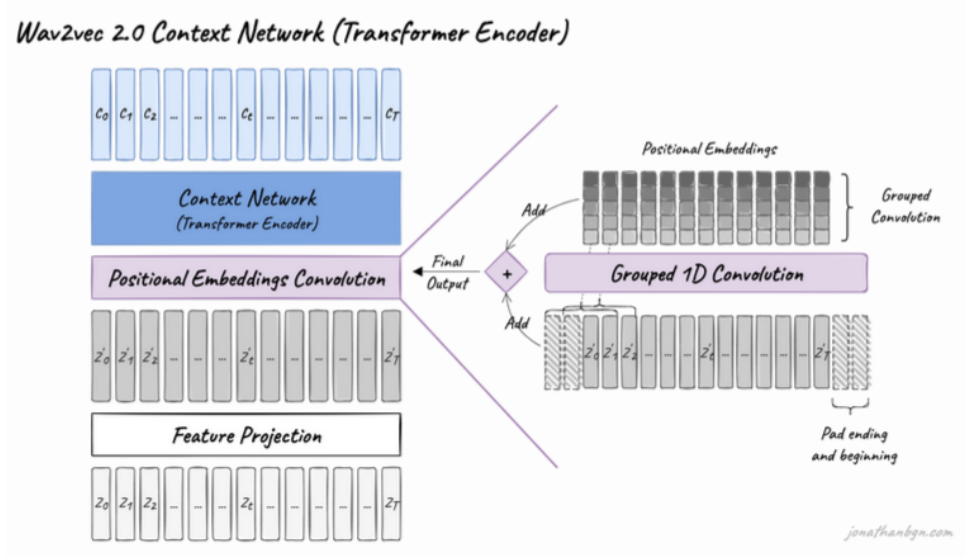


Figura 2.3: Arhitectura componentei Context Network <sup>1</sup>

## Quantization Module

Deoarece modelul *wav2vec 2.0* folosește pentru partea de Context Network un encoder de tip Transformer, ne confruntăm cu problema structurii continue a semnalului audio. Limbajul scris poate fi discretizat într-un set finit de simboluri, în timp ce semnalul audio nu permite în mod direct acest lucru. Astfel, modelul *wav2vec 2.0* folosește un modul de cuantizare care învață automat unități de vorbire din semnalul audio. Intuitiv, se încearcă găsirea unor sunete fonetice finite și reprezentative pentru ieșirile din Latent Feature Encoder. De asemenea, se aplică funcția Gumbel Softmax [5], funcție diferențiabilă care permite antrenarea modelului prin backpropagation. 2.4

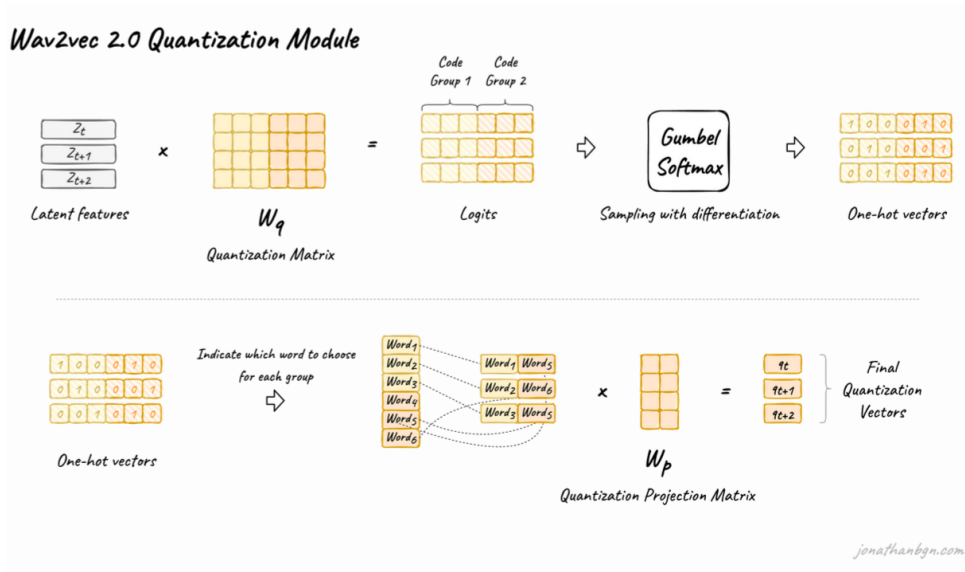


Figura 2.4: Arhitectura componentei Quantization Module <sup>1</sup>



## Contrastive Loss

Pentru antrenarea modelului folosește o mască care ascunde 50% din vectorii proiectați din spațiul latent înainte să fie trecuți prin Context Network. Acest lucru forțează modelul să învețe reprezentări între vectorii proiectați și vectorii ascunși. Pentru fiecare poziție mascată, se alege uniform aleator 100 de exemple negative de la alte poziții și se compară similaritatea cosinus între vectorul proiectat și vectorii aleși. Astfel, funcția de pierdere contrastivă încurajează similaritatea cu exemplele true positive și penalizează similaritatea cu exemplele false positive.




Figura 2.5: Arhitectura componentei Contrastive Loss <sup>1</sup>

### 2.1.2 Setul de date

Modelul oficial a fost preantrenat pe setul de date *LibriSpeech*, iar eu am continuat antrenarea pe seturile de date *Mini LibriSpeech* și *Common Voice Delta Segment 16.1*.

### Mini-LibriSpeech

*Mini LibriSpeech* este un subset al setului de date *LibriSpeech* care conține aproximativ 2 ore de înregistrări audio la o frecvență de eșantionare de 16 kHz. În medie, fiecare înregistrare are o durată de 6.72 secunde, cel mai lung audio având o durată de 31.5 secunde.

<sup>1</sup>Imaginile au fost preluate de pe site-ul lui Jonathan Bgn, "Illustrated Wav2Vec 2.0", disponibil la: <https://jonathanbgn.com/2021/09/30/illustrated-wav2vec-2.html>.

## Common Voice Delta Segment 16.1

*Common Voice Delta Segment 16.1* este un subset al setului de date *Common Voice* care conține aproximativ 2 ore de înregistrări audio la o frecvență de eșantionare de 48 kHz. A fost nevoie să reduc frecvența de eșantionare la 16 kHz pentru a putea folosi aceste date la antrenarea modelului. În medie, fiecare înregistrare are o durată de 5.63 secunde, cel mai lung audio având o durată de 10.47 secunde.

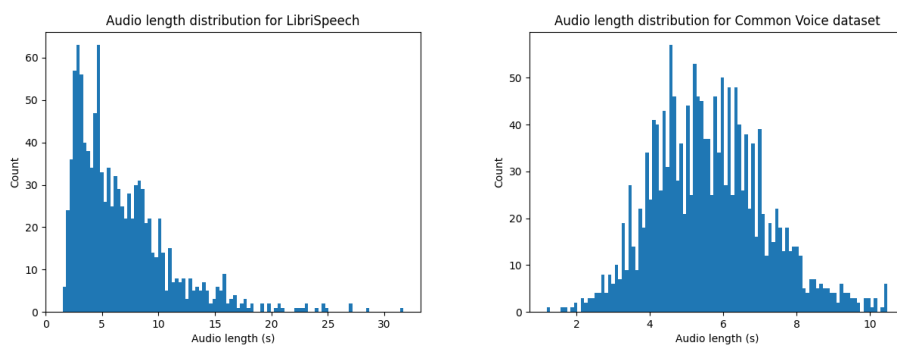


Figura 2.6: Distribuția duratelor audio-urilor din seturile de date *Mini LibriSpeech* și *Common Voice Delta Segment 16.1*

## Concluzie

Menționez aceste detalii deoarece pentru generarea subtitrărilor vom avea nevoie de audio-uri mult mai lungi decât cele folosite pentru antrenare care nu ar încăpea în memorie. Astfel, va trebui să folosim o tehnică de segmentare a audio-urilor în bucăți mai mici pentru a putea procesa audio-urile mai lungi. Mai multe detalii despre această tehnică vor fi prezentate în secțiunea *Subtitări*.

**2.1.3    Antrenarea modelului**

**2.1.4    Postprocesare**

**2.2    Clasificarea videoclipurilor**

**2.2.1    Arhitectura modelului**

**2.2.2    Setul de date**

**2.2.3    Antrenarea modelului**

**2.2.4    Postprocesare**

**2.3    Concluzii**

# Capitolul 3

## Inginerie software

### 3.1 Frontend

### 3.2 Backend

#### 3.2.1 Server

#### 3.2.2 Recunoașterea vorbirii

#### 3.2.3 Clasificarea videoclipurilor

### 3.3 Baze de date

#### 3.3.1 MongoDB

#### 3.3.2 Elasticsearch

# Bibliografie

- [1] Rosana Ardila, Megan Branson, Kelly Davis, Michael Henretty, Michael Kohler, Josh Meyer, Reuben Morais, Lindsay Saunders, Francis M. Tyers și Gregor Weber, *Common Voice: A Massively-Multilingual Speech Corpus*, 2020, arXiv: [1912.06670 \[cs.CL\]](#).
- [2] Alexei Baevski, Henry Zhou, Abdelrahman Mohamed și Michael Auli, *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*, 2020, arXiv: [2006.11477 \[cs.CL\]](#).
- [3] Pamela Bump, „How Video Consumption is Changing in 2023”, în *HubSpot* (Apr. 2023), URL: <https://blog.hubspot.com/marketing/how-video-consumption-is-changing>.
- [4] Elasticsearch, URL: <https://www.elastic.co/>.
- [5] Eric Jang, Shixiang Gu și Ben Poole, *Categorical Reparameterization with Gumbel-Softmax*, 2017, arXiv: [1611.01144 \[stat.ML\]](#).
- [6] Vassil Panayotov, Guoguo Chen, Daniel Povey și Sanjeev Khudanpur, „Librispeech: An ASR corpus based on public domain audio books” (2015), pp. 5206–5210, DOI: [10.1109/ICASSP.2015.7178964](#).
- [7] Steffen Schneider, Alexei Baevski, Ronan Collobert și Michael Auli, *wav2vec: Unsupervised Pre-training for Speech Recognition*, 2019, arXiv: [1904.05862 \[cs.CL\]](#).